



# Projecto de Sistemas de Informação

## Realizado por :

Paulo Chorinca

Carlos Neto

Diogo António

Bruno Mendes

Gonçalo Dias

## Índice

Resumo.....	4
O que são?.....	4
Para que serve? .....	4
Características gerais.....	4
Roleta – Seleção .....	5
Uniforme –Crossover –Recombinação.....	8
Esquema 1 .....	8
Esquema 2 .....	8
Observação /Problema.....	9
Operados <b>treincation –substituição</b> .....	9
Mochila :Problema .....	10
Reparação: aleatório .....	11
Anexos .....	12
Reparação:Psenda - Aleatória .....	13
Problema do caixeiro viajante.....	14
Descrição .....	14
Esquemas: .....	14
Cálculo do Fitness:.....	15
Reparar /Mitigar Programa .....	16
Order Crossover .....	17
Descrição .....	17
Esquema .....	17
SUS – Problema de Minimização.....	19
Esquema .....	19
Comparação de valores:.....	19
SwapGenes: Mutação .....	20
Descrição .....	20
Esquemas .....	20
Anexos .....	21
Função de avaliação .....	22
Valor do indivíduo .....	22
Seleção .....	22
Recombinação .....	23

Mutação .....	23
Intermediate recombination .....	24
Anexos .....	26
Fluxogramas .....	27
Fitness Penalização .....	27
Reparação Aleatória .....	27
Reparação Pseudo Aleatória .....	28
Operador Roleta .....	28
Operador Crossover .....	29
Operador SUS .....	30
Operador Truncation .....	30
Crossover .....	31
Inversion Mutation .....	32
Mutation .....	33
PMX .....	34
Crossover .....	35
Mutação Binária .....	36
P.S.O .....	37
Recombinação Binária .....	38
Pseudo-codigo .....	39
Fitness Penalização .....	39
Reparação aleatória .....	39
Reparação aleatória .....	40
Operador crossover .....	40
Operador Roleta .....	41
Operador SUS .....	41
Operador Truncation .....	42
Crossover .....	43
Inversion Mutation .....	44
Mutation .....	44
PMX .....	45
SUS Minimização .....	45
Crossover .....	46
Mutação binária .....	46

PSO .....	47
Recombinacao_binaria.....	47

## Resumo

Desenvolveu-se neste trabalho a implementação computacional de um algoritmo genético.

Este se constituiu de uma população inicial sobre a qual agem, operadores fundamentais uma nova população.

Sobre a qual agem novamente os operadores genéticos, e assim sucessivamente produzindo uma sequência de populações. O operador *seleção* foi implementado em dois algoritmos básicos: *roleta* e *torneio*. A *substituição* de indivíduos da população pelos filhos ocorre de três maneiras básicas: *dos pais, dos menos aptos, e dos indivíduos sorteados aleatoriamente*.

## O que são?

- Os Algoritmos Genéticos são uma classe de procedimentos, com passos distintos bem definidos.
- Essa classe se fundamenta em analogias a conceitos biológicos já testadas à exaustão.
- Cada passo distinto pode ter diversas versões diferentes

## Para que seve?

- Busca e Otimização
- Amplamente utilizados, com sucesso, em problemas de difícil manipulação pelas técnicas tradicionais
- Eficiência X Flexibilidade



## Características gerais

- Utilizam uma codificação do conjunto de
- Parâmetros (indivíduos) e não como próprios parâmetros (estados);
- Vasculham várias regiões do espaço de busca de cada vez;
- Utilizam informações diretas de qualidade, em contraste com as derivadas utilizadas nos métodos tradicionais de otimização;
- Utilizam regras de transição probabilísticas
- e não regras determinísticas

## Roleta – Seleção

1. Atribuir uma percentagem a cada individuo de uma população com base no fitness e no total de fitness da população ;
2. Juntar os indivíduos em linha de forma a criar percentagens acumuladas, com base na ordem dos indivíduos;
3. Gerar um numero real aleatório entre 0 e 1
4. Seleccionam o individuo para onde o número aponta;
5. Repetir os passos 3º e 4º ate ter o número de indivíduos pretendidos.

Exemplo: Seleccionam 4 indivíduos numa população de 6 indivíduos.



A	B	C	D	E	F
---	---	---	---	---	---

0,2	0,1	0,69	0,5
A	A	C	B

1. Juntos todos os indivíduos de uma população pela ordem que se encontram, de forma a fazer uma linha com os indivíduos

Indi A	Indi B	Indi C	Indi D	... N Indivíduos
--------	--------	--------	--------	------------------


2. Fazer a soma do fitness do individuo anterior ao ser, com base na ordem em que se encontram na linha;
3. Obter o total do somatório de todos os fitness, o fitness do ultimo individuo, pois é o acumulado de todos os indivíduos;
4. Gerar um ponto aleatório, inteiro ou real, dentro do intervalo 0 e total do fitness de todos os indivíduos, para ser o nosso ponto de partida;
5. Definir qual vai ser o offset que se vai acrescentar ao ponto de partido. Calcula através

Total fitness


Total nº indivíduos


6. Selecionar o individuo para onde o ponto aponta;
7. Somar ao ponto o offset;
8. Repetir os pontos 6º e 7º ate obter o numero de indivíduos selecionados pretendidos;
9. Caso se atinja o fim da linha de indivíduos então volta se ao inicio da linha

Exemplo: população 10 indivíduos e devemos escolher 6 indivíduos para reprodução





$$\text{offset} = \frac{\text{total fitness}}{\text{total nº indivíduos}} = \frac{66}{10} = 6.6$$





Individuos  
seleccionados



Individuos Seleccionados



## Uniforme –Crossover –Recombinação

1. Ter dois indivíduos, um “pai” e uma “mãe”
2. Gerar uma cadeia de bits, ou mascara, para determinar quais os bits que não ser traçados;

Nota: A mascara tem que ter as mesmas dimensões do gene dos indivíduos pais

3. Para cada bit a “1” na mascara vai haver uma troca

Exemplo: Dois pais com genes de tamanho de 10 bits e gerar dois filhos usando o operador uniform – crossover .

### Esquema 1

Pai	1	0	0	0	1	1	1	0	1	0	pais
Mãe	0	0	0	1	1	1	0	0	0	1	
											mascara
Filho1	0	0	0	1	1	1	1	0	0	1	filhos
Filho2	1	0	0	0	1	1	0	0	1	0	

### Esquema 2

Pai	1	0	0	0	1	1	1	0	1	0	pais
Mãe	0	0	0	1	1	1	0	0	0	1	
											mascara
filho	0	0	0	1	1	1	1	0	0	1	filhos
filha	1	0	0	0	1	1	0	0	1	0	

## Observação /Problema

Se a mascara for toda a "0" o indivíduos filho vai ser igual ao pai e o individuo filha vai ser igual a mãe.

### Solução


Garantir que 50% dos bits da mascara são a "1" e os restantes a "0".

Os 50% referidos anterior mente pode ser um parâmetro deste operada, sendo 50% o valor recomendado por defeito

## Operados **treincation -substituição**

1. Ter duas populações, ou mais para aplicar o operador;
2. Juntar os varias populações numa só
3. Ordenar, com base no fitness de cada individuo, de forma descendente
4. Selecionar os indivíduos que surgem primeiro e criar uma nova população

Exemplo: Duas populações com 5 indivíduos cada, onde se quer criar uma nova população com 5 indivíduos




Indivíduos ordenados



Os indivíduos das duas populações juntos e ordenados

Os 5 primeiros indivíduos



Nova  
População

os 5 indivíduos  
com melhor fitness  
selecionado

## Mochila :Problema

Problema: levar o maior número de peças na mochila, que tem um limite de peso, mas ao mesmo tempo levar o maior valor na mochila.

Peso	10	4	1	10	5
Valor	5	3	10	1	3

Máximo peso possível na mochila: 16

0	0	1	1	0	VALOR :11 ✓	
1	1	0	0	1	VALOR :11 ✓	
1	1	1	1	0	VALOR :11 ✓	
1	1	1	1	1	VALOR :11 ✓	

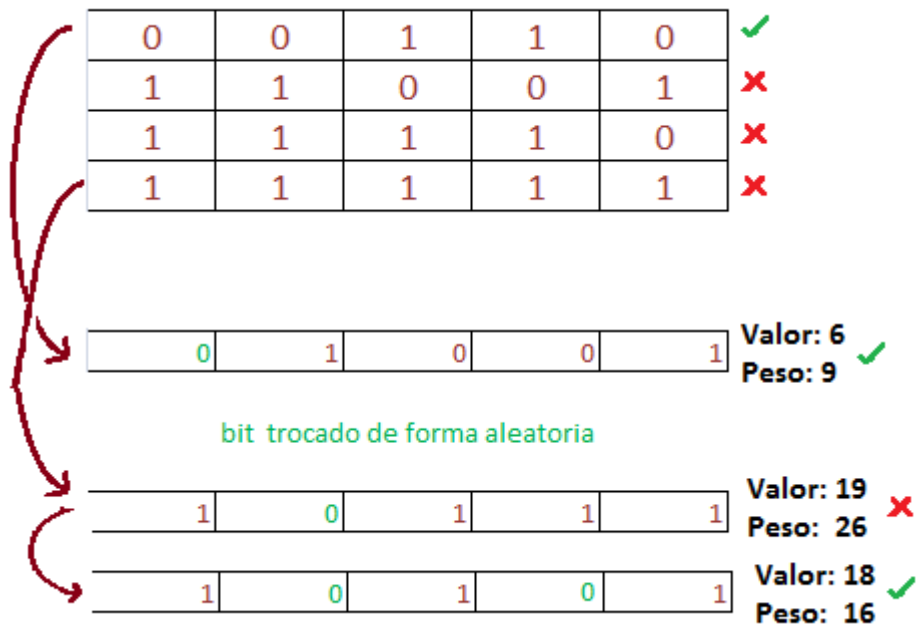
Penalização por excesso  
de peso no fitness

Tipos de penalizações

Linear:  $-3^1=3$  (usada no exemplo anterior)

Quadrática:  $-3^2=9$

## Reparação: aleatório



Repetir o processo ate ter um peso aceitável

Só troca os bits que estão a “1”, pois são esses que estão a fazer a indivíduos / mochila ter peso a mais.

Exemplo: dos bits que podem ser trocados na reparação:



## **Anexos**

[Mochila Fitness Penalização](#)  
[Mochila Reparacao Aleatoria](#)  
[Mochila Reparacao Pseudo Aleatoria](#)  
[Mochila-part1](#)  
[Mochila-part2](#)  
[Mochila-part3](#)  
[Mochila-part4](#)  
[Operador Roleta](#)  
[Operador SUS](#)  
[Operador Truncation](#)  
[Operator Truncation](#)  
[pseudo-codigo mochila fitnessPenalizacao](#)  
[pseudo-codigo mochila reparacao aleatoria](#)  
[pseudo-codigo mochila reparacao pseudo-aleatoria](#)  
[pseudo-codigo Operador crossover](#)  
[pseudo-codigo Operador Roleta](#)  
[pseudo-codigo Operador SUS](#)  
[pseudo-codigo Operador Truncation](#)  
[Relatorio Final](#)  
[Roleta](#)  
[SUS-part1](#)  
[SUS-part2](#)  
[UniformCrossover-part1](#)  
[UniformeCrossover-part2](#)  
[Esquemas 1](#)  
[Esquemas 2](#)  
[Esquemas 3](#)  
[Esquemas 4](#)  
[Esquemas 5](#)  
[Esquemas 6](#)  
[Versao2](#)

## Reparação: Psenda - Aleatória


Peso	10	4	1	10	5
Valor	5	3	10	1	3
Valor/Peso	0,5	0,75	10	0,1	0,6

### Calculo de Relação

$$\text{Relação} = \frac{\text{Valor}}{\text{Peso}} = \frac{5}{10} = 0,5$$

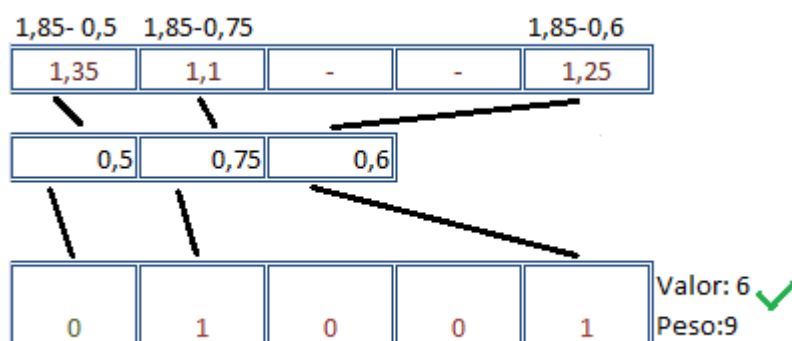
### Exemplo:

1	1	0	0	1
0,5	0,75	-	-	0,6



**Atenção:** Não podemos usar dessa forma tão direta porque as peças com melhor relação Valor / peso ficam com a maior probabilidade de serem escolhidos para saírem da mochila.

### Então:



## Problema do caixeiro viajante


### Descrição:

Problema de complexidade  $n!$ . Procura-se encontrar um, ou mais caminhos, para percorrer todas as cidades e voltar ao ponto de origem, sem nunca passar numa cidade duas vezes e obter o caminho com menos custo.

### Esquemas:

- Tamanho de gene igual ao numero de cidades;
- As cidades são indexadas para que as suas representações sejam números inteiros;
- As ordem com que os alelos aparecem no gene  $n^2$  a mesma ordem por qual passamos nas cidades.

### Representação Caminhos



### Custo


	A	B	C	D
A	-	2	4	1
B	2	-	1	5
C	4	1	-	3
D	1	5	3	-

### Representação Gene

0	1	2	3
---	---	---	---



Cidade	A	B	C	D
Índex	0	1	2	3

Ordem:





### Cálculo do Fitness:


- Exemplo 1



- Exemplo 2








São sempre o mesmo caminho,  
começam é em pontos diferentes

## Reparar /Mitigar Programa

Pegar na cidade **0** e por como primeira cidade através de uma rotação, para o mesmo caminho só ter uma representação.



Transforma-se numa única  
representação

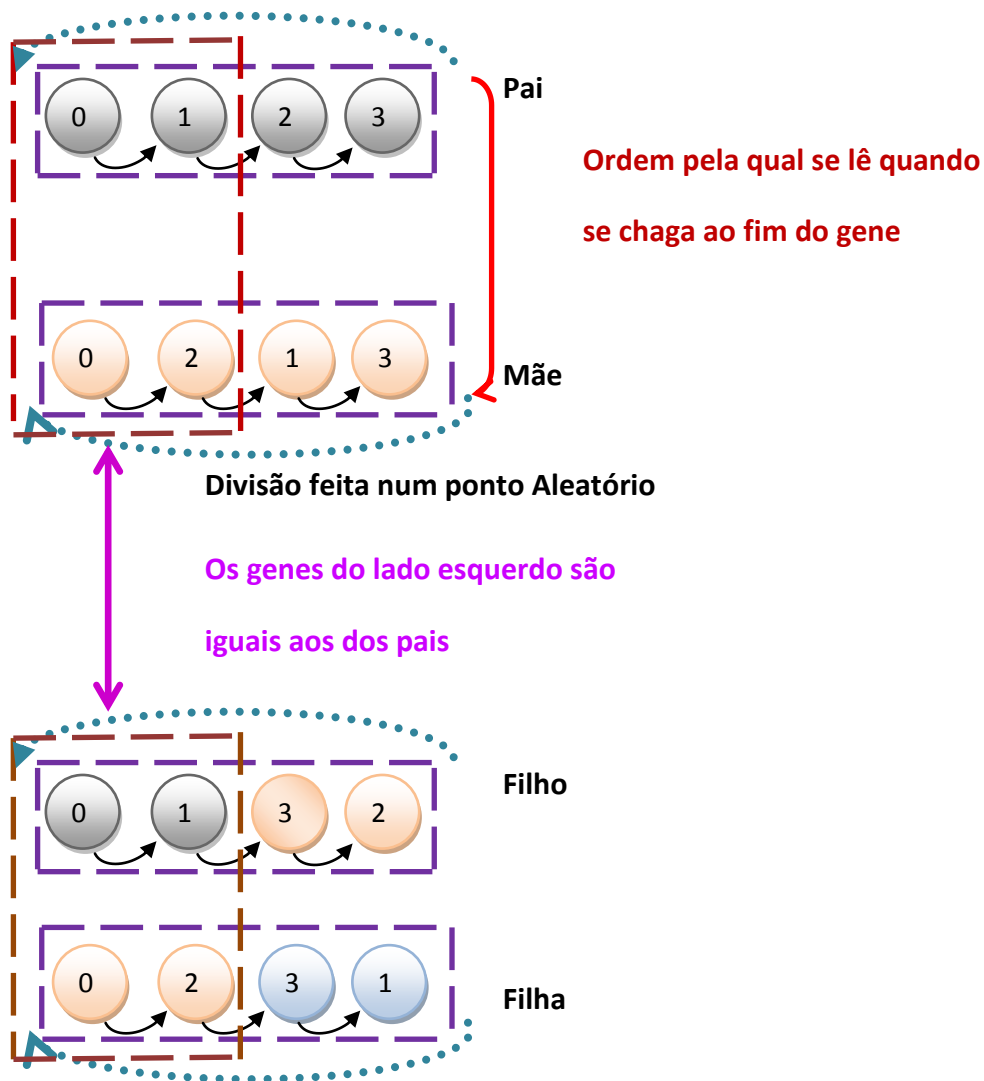
fazemos isso, só partir o gene em dois no ponto onde aparece o **0**, depois criamos um novo gene com a ( **2ª parte**) em primeiro e a ( **1ª parte**) em segundo, e assim fica o **0** sempre como cidade de partida.


## Order Crossover

### Descrição

Uma parte do pai é mapeado para uma porção da mãe. A partir da porção substituída, o resto dos genes são preenchidos mas omitindo os genes já presentes e respeitando a ordem com que eles se encontram.

### Esquema





## Código

```

Entra (Individuo pai, mae Individuo)

dim: = TAMANHO (pai.genes [])

corte: = aleatorio ([1; dim-1])

Pará i: = 0 comeu i < corte
    filho.gene [i]: = pai.gene [i]
    filha.gene [i]: = mae.gene [i]
    i: = i +1

n J: = corte comeu j < dim
    filho.gene [j]: = Procura (j, mae.gene [], filho.gene [])
    filha.gene [j]: = Procura (j, pai.gene [], filha.gene [])
    j: = j +1

sai (Individuo Filho, Individuo FILHA)


Procura (pos, progenitor.gene [], descendente.gene [])
    p: = pos-1
    q: = pos
    enquanto (p >= 0)
        se (descendente.gene [p] = progenitor.gene [q]) entao
            q: = q +1
            q: = q% TAMANHO (progenitor.gene [])
            p: = pos
        p: p-1 =
    Retorna progenitor.gene [q]

```

## SUS – Problema de Minimização

### Esquema

População



Max(população) = 12

Min(população) = 1

Pseudo-código: Cálculo do novo Fitness:

**inteiro** converterFitness (população, fitness)

**MaxFitness** := Max(população) + 1

**return** MaxFitness – fitness

### Comparação de valores:

	A	B	C	D	E	F	G	H	I	J
<b>Fitness</b>	10	5	7	7	5	1	2	8	9	12
<b>Novo Fitness</b>	3	8	6	6	8	12	11	5	4	1

Como se pode ver pelos valores da tabela anterior, os valores originais com maior fitness, passam a ser os que têm menor fitness neste momento e os que tinham menor, passam a ter os maiores valores de fitness.

Antes

A	B	C	D	E	F	G	H	I	J
---	---	---	---	---	---	---	---	---	---

66

Depois

A	B	C	D	E	F	G	H	I	J
---	---	---	---	---	---	---	---	---	---

64


Nota: Não esquecer que neste SUS procuramos o valor mais pequeno de fitness, mas o SUS “não devolve os valores mais pequenos”, logo tivemos que transformar os valores grandes em valores pequenos e fazer o contrário com os valores pequenos.

## SwapGenes: Mutação

### Descrição

Temos um individuo onde escolhemos dois **delos**, de forma aleatória, e os trocamos de sitio.

### Esquemas



Dois pontos aleatórios que apontam para  
Dois deles

Depois é só fazer o troca de posições

### Código

```
Entra (População individuos [])

dimPop: = TAMANHO (individuos [])
dimGene: = TAMANHO (. individuos [] genes [])

Pará i: = 0 i = comeu dimPop
    alelo1: = aleatorio ([0; dimGene []]
    Fazer
        alelo2: = aleatorio ([0; dimGene []]
        enquanto (alelo1 = alelo2)

        aleloTmp: = individuos [i] genes [alelo1]
        individuos [i] genes [alelo1]:. individuos. = [i] genes [alelo2]
        individuos [i] genes [alelo2]:. = aleloTmp
        i: = i +1

sai (População individuos [])
```

## [Anexos](#)

[DemoTSP](#)

[TSP](#)

[Apresentação Caixeiro Viajante](#)

[CaxeiroViajante-Part1](#)

[CaxeiroViajante-Part2](#)

[CaxeiroViajante-Part3](#)

[cycleCrossover\(fluxograma\)](#)

[cycleCrossover](#)

[pseudo-codigo cycleCrossover](#)

[InversionMutation](#)

[InverctionMutation](#)

[pseudo-codigo InverctionMutation](#)

[Mutation](#)

[pseudo-codigo Mutation](#)

[PMX](#)

[PMX](#)

[PMX\\_1](#)

[PMX\\_2](#)

[Relatorio\\_Final](#)

[SUS Minimizacao](#)

[pseudo-codigo SUS Minimizacao](#)

[SUS Minimizacao-Part1](#)

[SUS Minimizacao-Part2](#)

[SwapGenes fluxograma](#)

[Swapgenes](#)

[pseudo-codigo Swapgenes](#)

[Versao3](#)

## Função de avaliação

$$f(x_1, x_2) = 21.5 + x_1 \sin(4\pi x_1) + x_2 \sin(20\pi x_2)$$

$$\text{com, } -3,0 \leq x_1 \leq 12,1 \text{ e } 4,1 \leq x_2 \leq 5,8$$

Representação binária para 4 casas decimais :

$$Dx_1 = \underline{15,1} = 12,1 - (-3,0)$$

$$15,1 * 10\,000 = 15100 \quad \Rightarrow \quad 2^{17} \leq 151000 \leq 2^{18}$$

$$Dx_2 = \underline{1,7} = 5,8 - 4,1$$

$$1,7 * 10\,000 = 17000 \quad \Rightarrow \quad 2^{14} \leq 17000 \leq 2^{15}$$

Indivíduo  $i$  é composto de 2 genes ( $x_1$  e  $x_2$ )

$$\left\{ \begin{array}{l} X_1 = 18 \text{ alelos} \\ X_2 = 15 \text{ alelos} \end{array} \right.$$

**Exemplo:**

1	1	1	1	0	1	0	0	1	0	1	0	1	1	1	0	0	0
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---

$$X_1 = \quad \quad \quad = 250552d$$

0	0	1	0	0	1	0	1	1	0	0	0	0	0	0		
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	--	--

$$X_2 = \quad \quad \quad = 4800d$$

$$X'_1 = -3 + 250552 + \frac{15,1}{2^{18}-1} = 11,4323$$

$$X'_2 = 4,1 + 4800 + \frac{1,7}{2^{15}-1} = 4,3490$$

### Valor do indivíduo

$$\text{Avaliação} = f(11,4323 ; 4,3490) = \underline{\underline{13,1733}}$$


### Seleção

Ordena-se a população (por exemplo: através da roleta) colocando neste caso (maximização) no topo da lista os indivíduos que obtiverem maior valor calculado através da função de avaliação.

## Recombinação

1. Escolhem-se 2 indivíduos do topo da lista obtida (que ainda não tivessem sido escolhidos)
2. Calcula-se um numero aleatório entre  $[0;1[$ 
  - 3.1 Se o numero aleatório for maior do que 0,65, os dois indivíduos escolhidos passam diretamente para a descendência.
  - 3.2 se o número aleatório for menor ou igual a 0.65, calcula-se aleatoriamente um ponto de corte para os primeiros genes dos dois indivíduos escolhidos recombina-os e procedendo de igual forma para os segundos genes de ambos. Passando para a descendência os dois indivíduos cujos novos genes são constituídos até aos cortes, pelos seus próprios e são contados em frente pelos do indivíduos com o qual recombina-ram.
- 4 volta-se ao ponto 1 até terminarem os indivíduos da lista ordenada.

### Exemplo



Indivíduos:  $i_1$  e  $i_2$

$$i_1 = x_1 \& x_2 \Leftrightarrow i_1 = a+b \& c+d$$

$$i_2 = x_1 \& x_2 \Leftrightarrow i_2 = A+B \& C+D$$

Recombinando fica:

$$i'_1 = a + B \& c + D$$

$$i'_2 = A + b \& C + d$$

## Mutação

1. É escolhida uma percentagem de mutação (por exemplo 1%)
2. É escolhido um individuo
3. É escolhido o primeiro gene: e para cada um dos alelos é calculada aleatoriamente uma percentagem, se essa percentagem for menos do que 1% o bit em causa passa a "1".
  - 3.1 É efetuada a mesma operação no segundo gene .
4. Volta-se ao ponto 2 até terminar a população.



Exemplo:

$i'_3 = 101101101000111010 \quad \& \quad 1110010001011110$

## Intermediate recombination

1. Seleccionam-se 2 indivíduos,  $P_1$  e  $P_2$ , assumindo o papel de “Pais” ( $P_1$  “Pai 1” )
2. Seleccionam-se os genes  $\text{Genes}_i^{P_1}$  e  $\text{Genes}_i^{P_2}$ , dos indivíduos  $P_1$  e  $P_2$  respetivamente , em que  $i \in \{1,2,3,\dots, \text{numero genes}\}$
3. Gera-se um número aleatório  $a$ ; pertencente ao intervalo  $[-0.25 ; 1.25]$
4. Calcula-se o gene  $\text{Genes}_i^F$  do novo indivíduo  $F \rightarrow$  “filho ”, através da seguinte formula.  

$$\text{Genes}_i^F = \text{Genes}_i^{P_1} * a_i + \text{Genes}_i^{P_2} * a_i$$
5. Volta-se ao ponto 2 até que todos os genes dos indivíduos ” Pais ”  $P_1$  e  $P_2$  sejam percorridos ( $i = \text{numero genes}$  ).



Exemplo

Considerar os seguintes indivíduos, com 3 genes cada

Pai 1	12	25	5
Pai 2	123	4	34
	Genes <sub>1</sub> <sup>P2</sup>	Genes <sub>2</sub> <sup>P2</sup>	Genes <sub>3</sub> <sup>P2</sup>

Considerar os seguintes valores de a para esta exemplo

$a_1$	$a_2$	$a_3$
0.5	1.1	-0.1

O novo filho calculado

	Genes <sub>1</sub> <sup>F</sup>	Genes <sub>2</sub> <sup>F</sup>	Genes <sub>3</sub> <sup>F</sup>
Pai 2	67.5	1.9	2.1

$$\begin{aligned}
 \text{Genes}_i^F &= \text{Genes}_i^{P1} * a_i + \text{Genes}_i^{P2} * (1 - a_i) \\
 &= 12 * 0.5 + 123 * (1 - 0.5) \\
 &= 6 + 61.5 \\
 &= 67.5
 \end{aligned}$$

## Anexos

[Demo](#)

[GeneticAlgorithm\\_real\\_coded](#)

[PSO DE GA](#)

[Differential Evolution](#)

[intermediate crossover](#)

[intermediate crossover parte1](#)

[intermediate crossover parte2](#)

[IntermediateCrossover](#)

[Mutation Binaria](#)

[otimizacao funcaoMat PDF](#)

[\\_pseudo-codigo Mutation binaria](#)

[P.S.O](#)

[PSO](#)

[pseudo-codigo PSO](#)

[Recombinacao Binaria](#)

[pseudo-codigo Recombinacao binaria](#)

[Relatorio Final4](#)

[Esquemas 1](#)

[Esquemas 2](#)

[Esquemas 3](#)

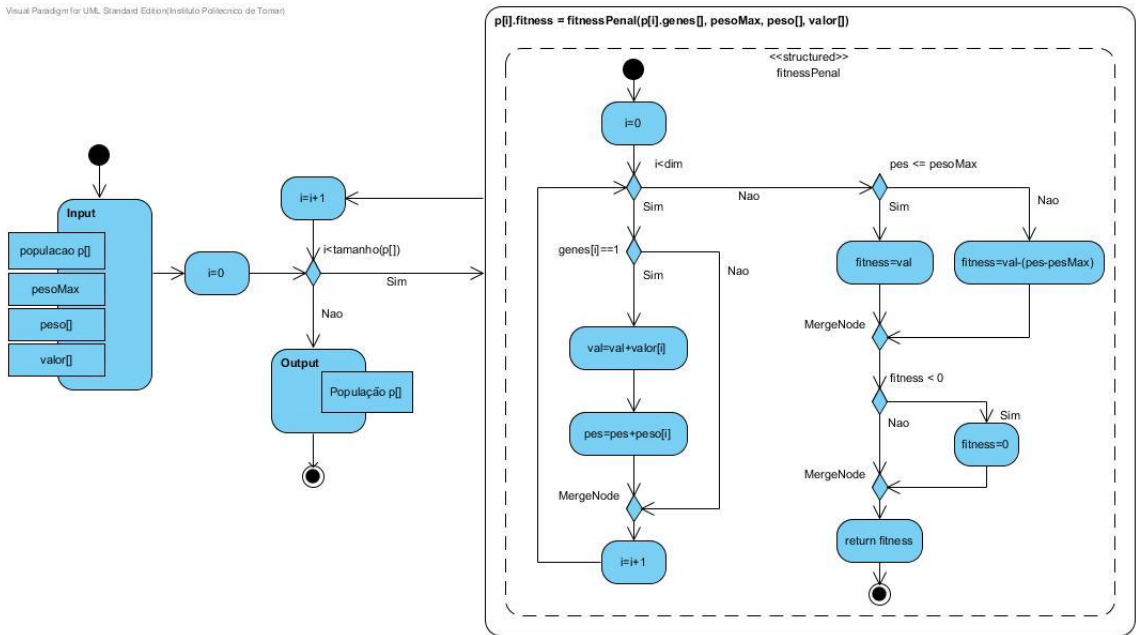
[solucaoDemo](#)

[Versao4](#)

# Fluxogramas

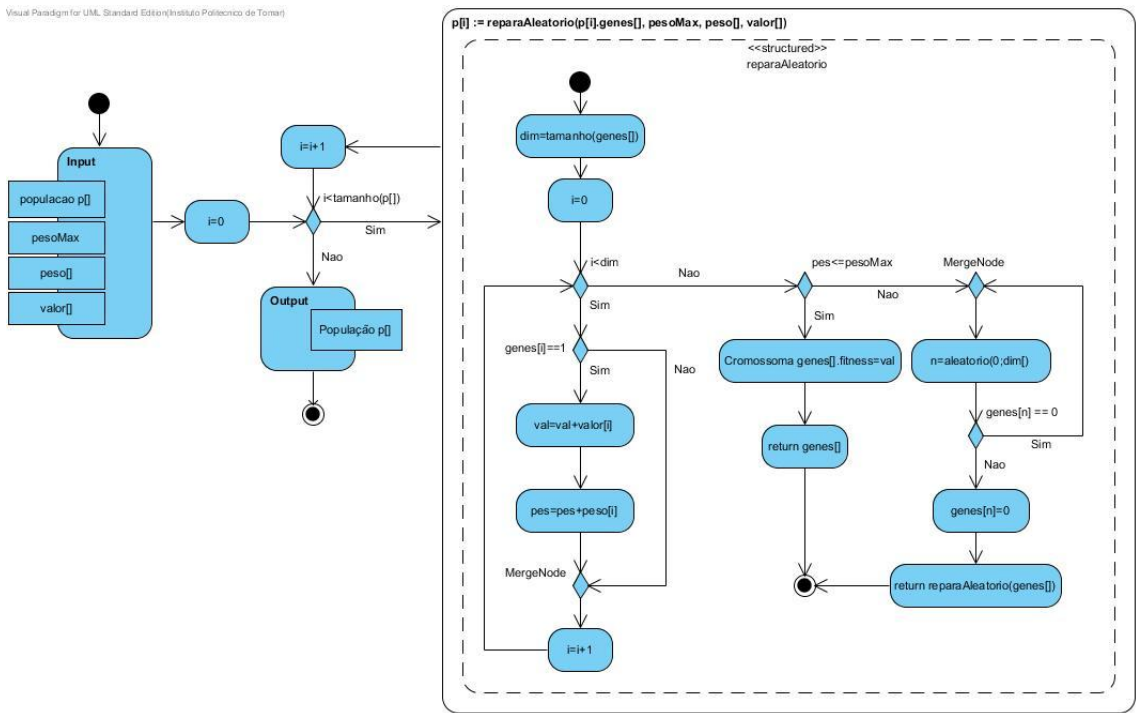
## Fitness Penalização

Visual Paradigm for UML, Standard Edition (Instituto Politécnico de Tomar)

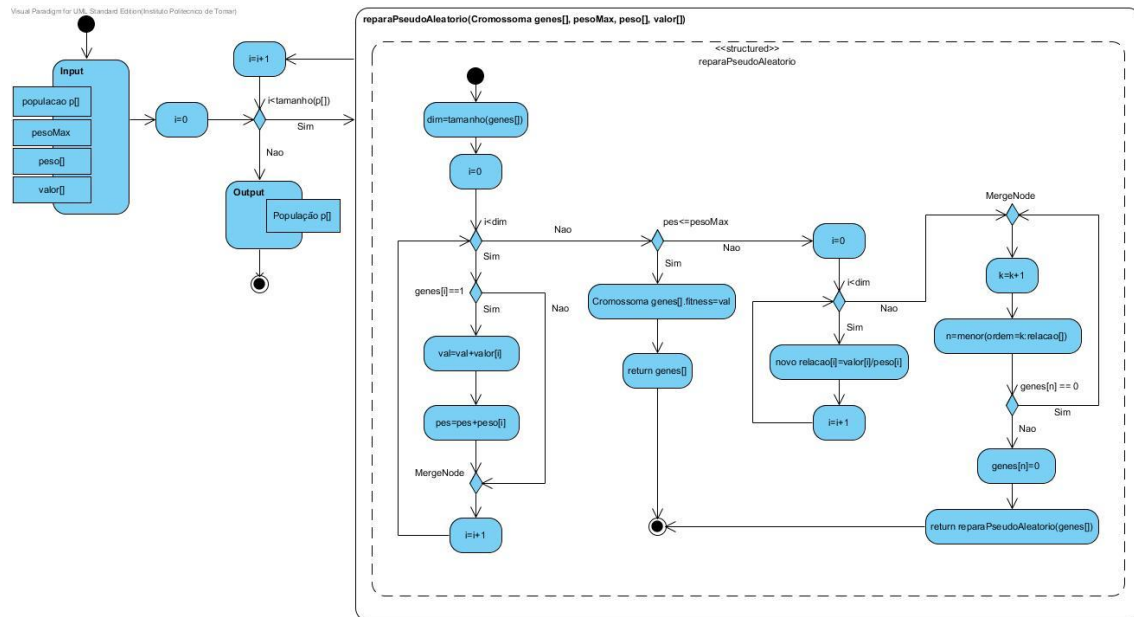


## Reparação Aleatória

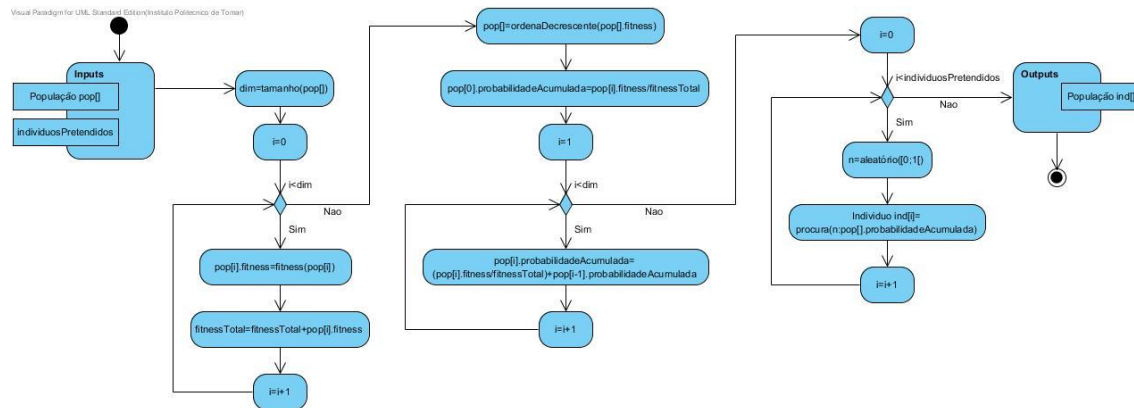
Visual Paradigm for UML, Standard Edition (Instituto Politécnico de Tomar)



## Reparação Pseudo Aleatória

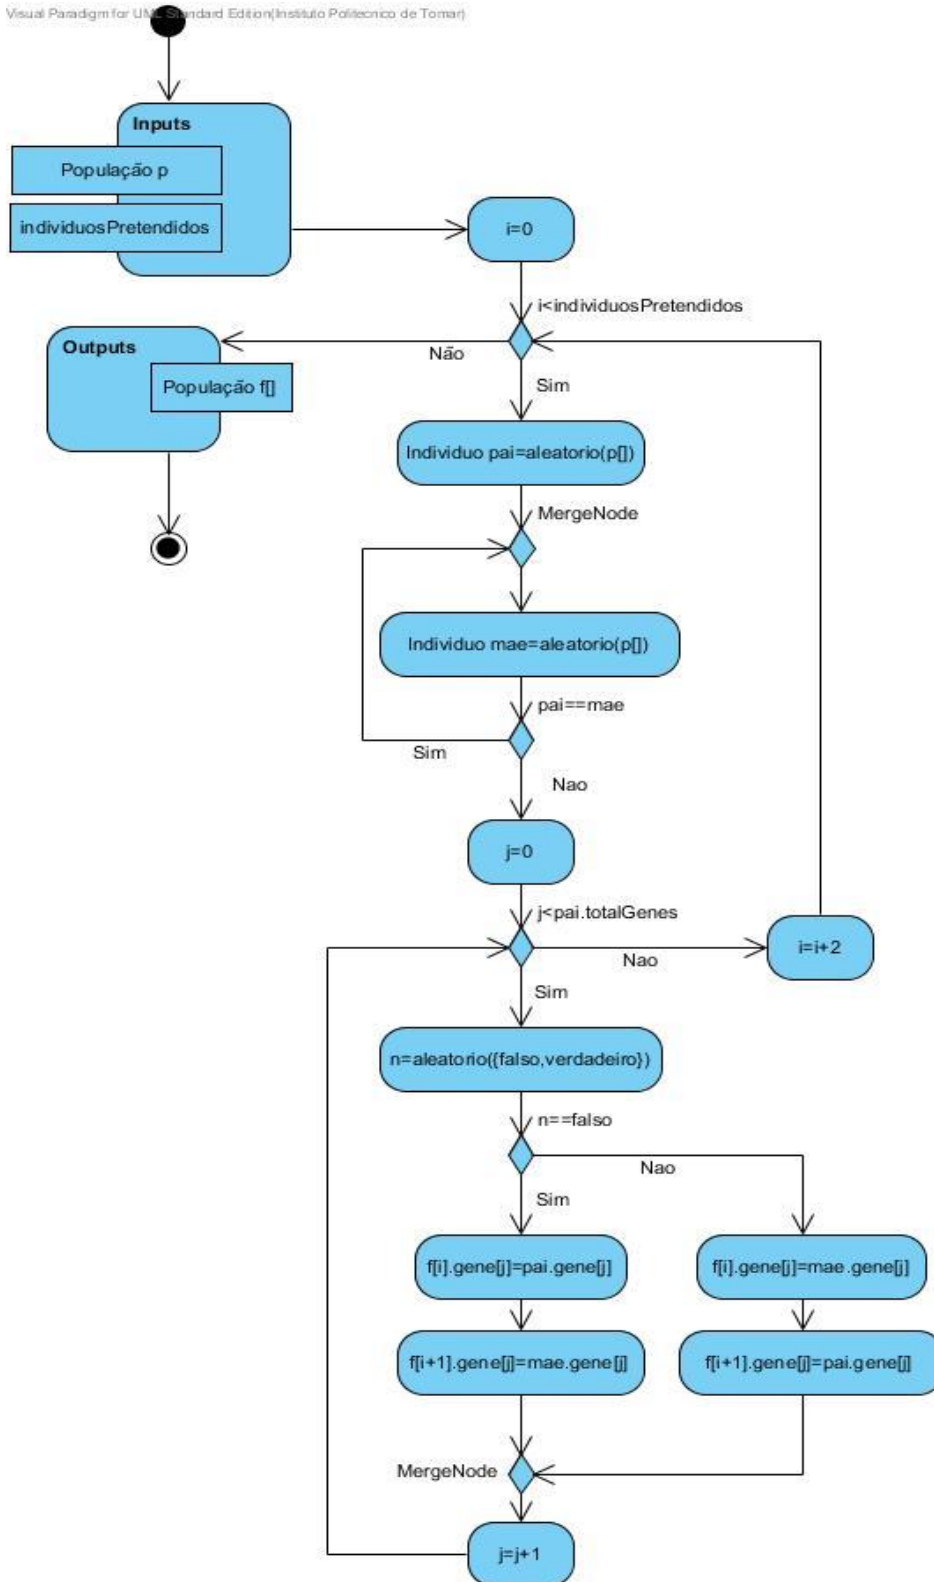


## Operador Roleta



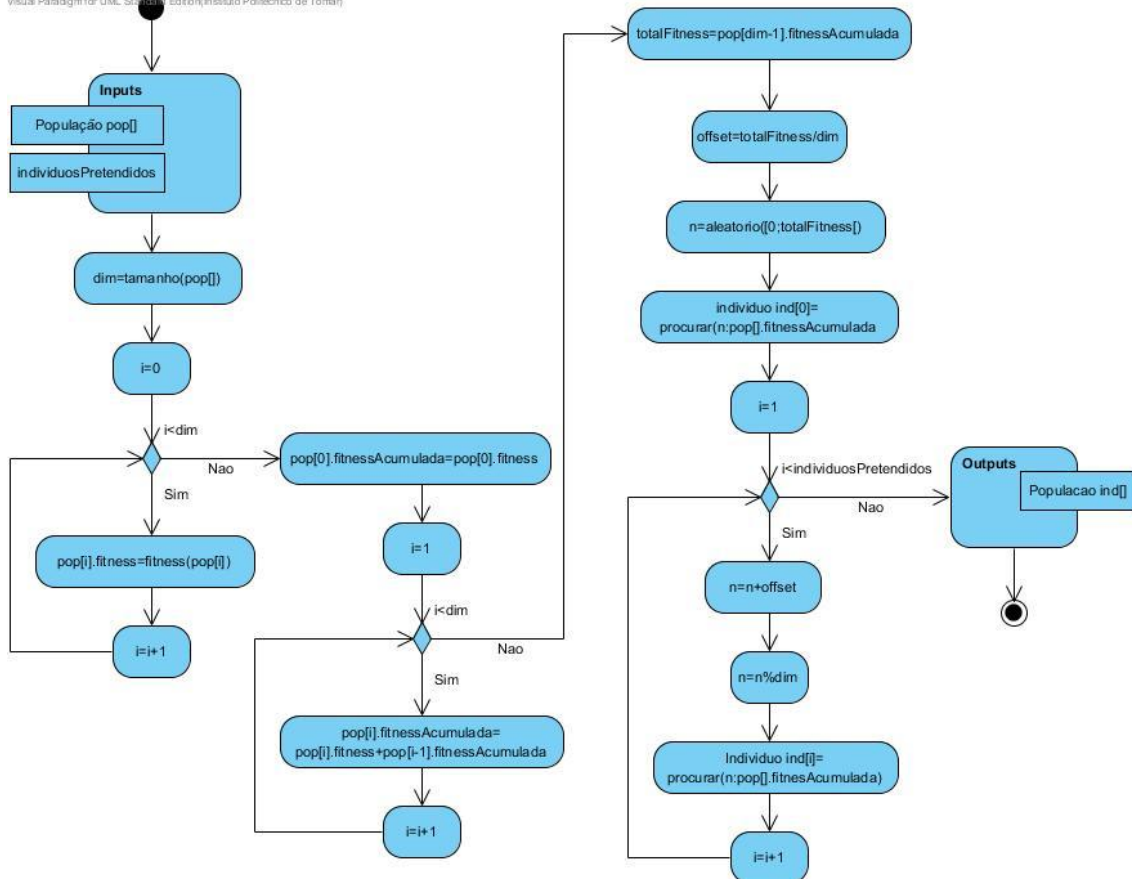
## Operador Crossover

Visual Paradigm for UML Standard Edition (Instituto Politécnico de Tomar)



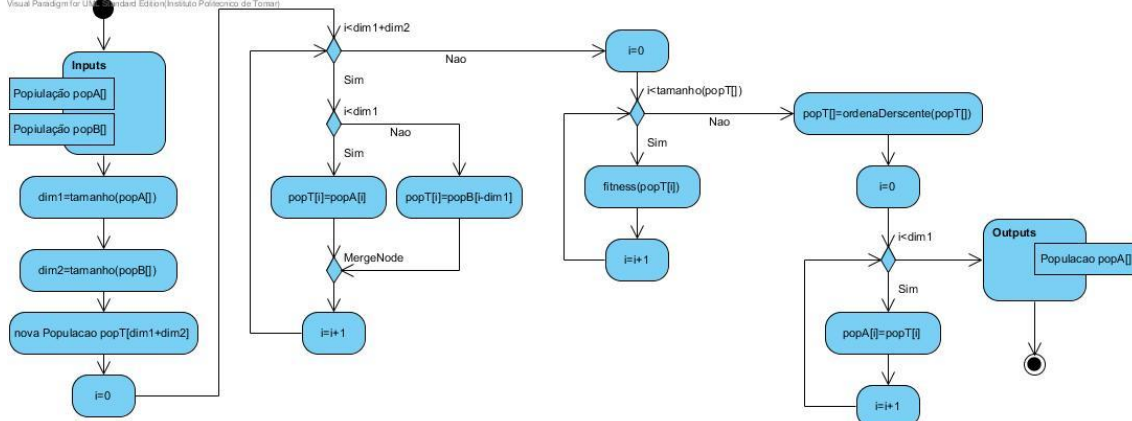
## Operador SUS

Visual Paradigm for UML, Standard Edition (Instituto Politécnico de Tomar)

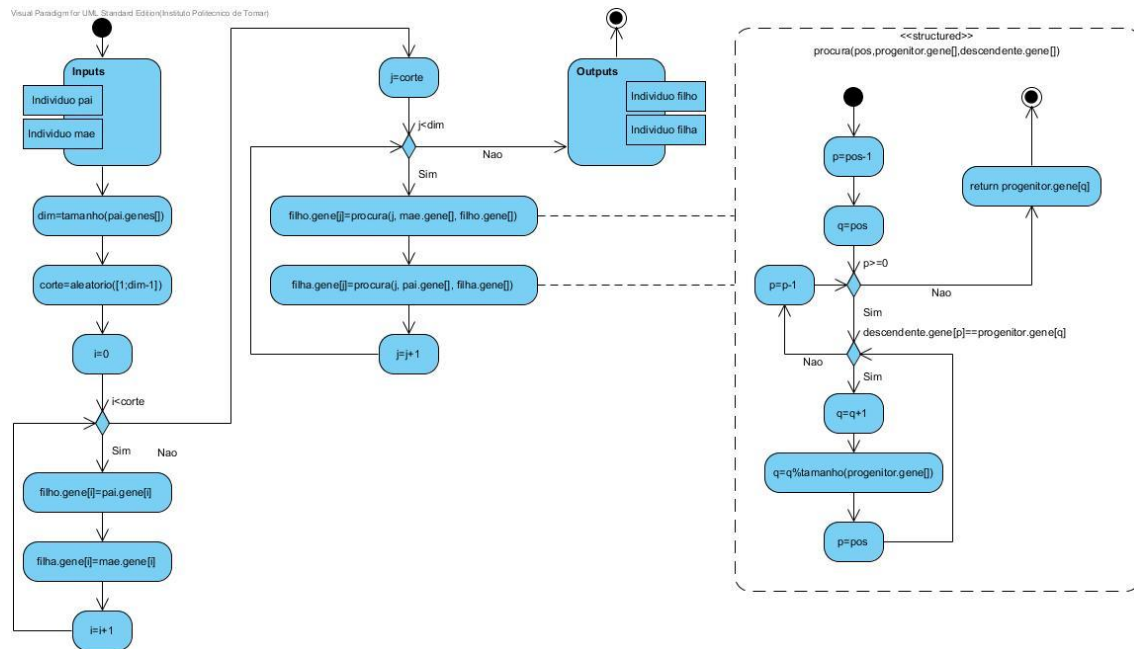


## Operador Truncation

Visual Paradigm for UML, Standard Edition (Instituto Politécnico de Tomar)



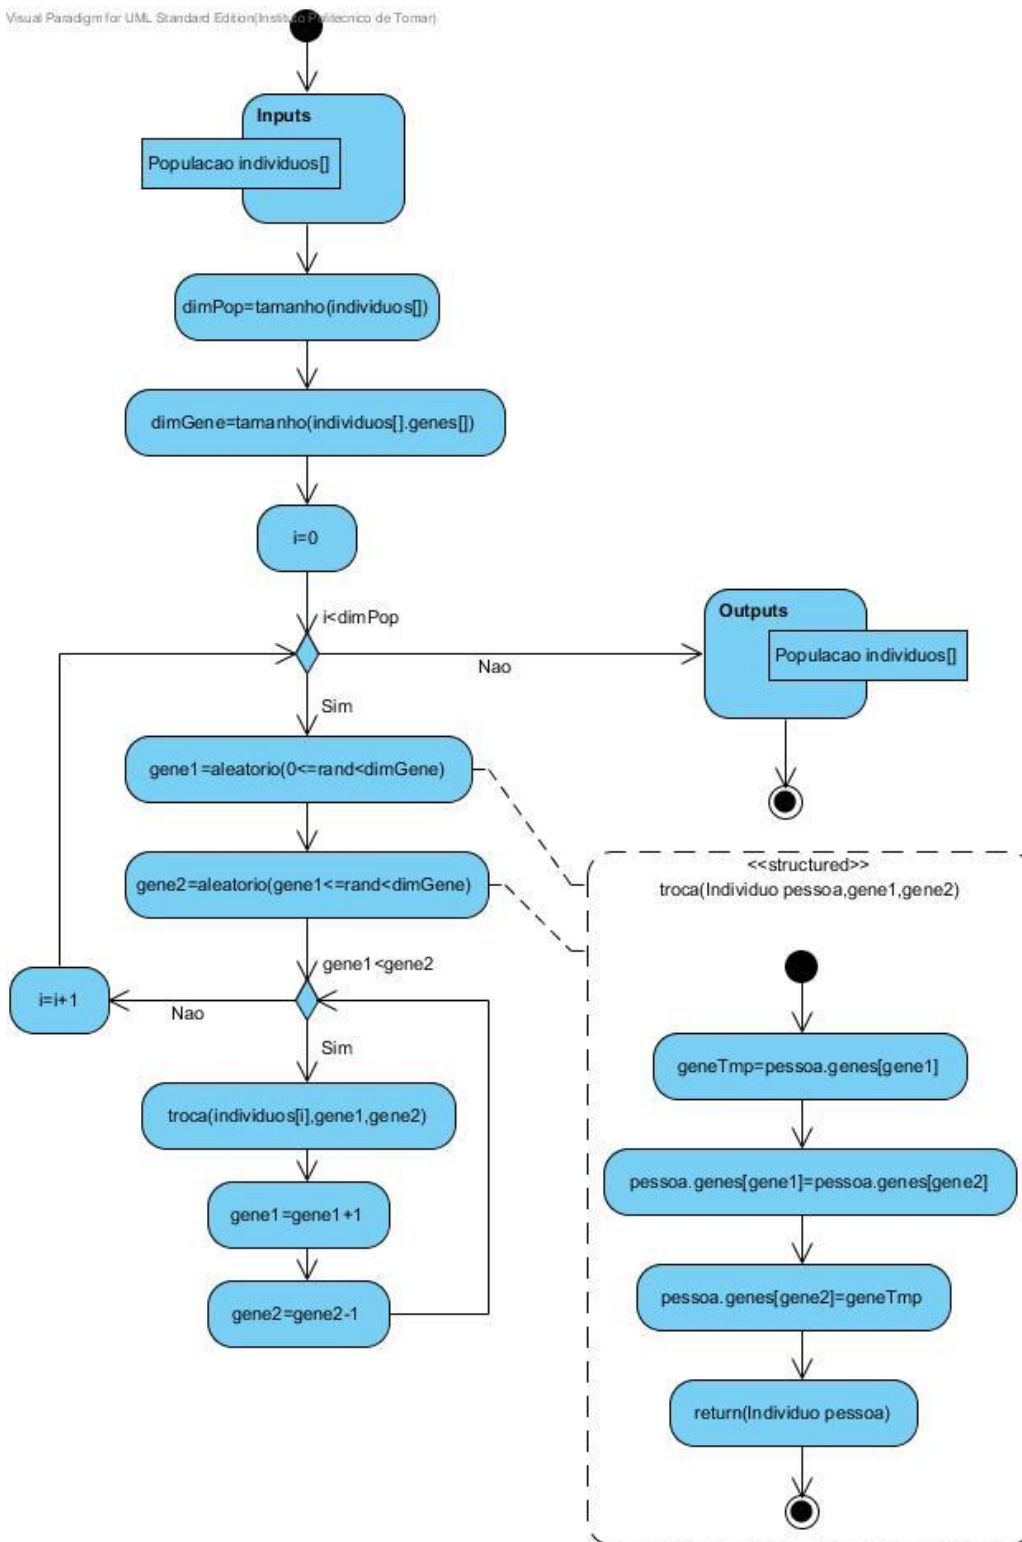
## Crossover





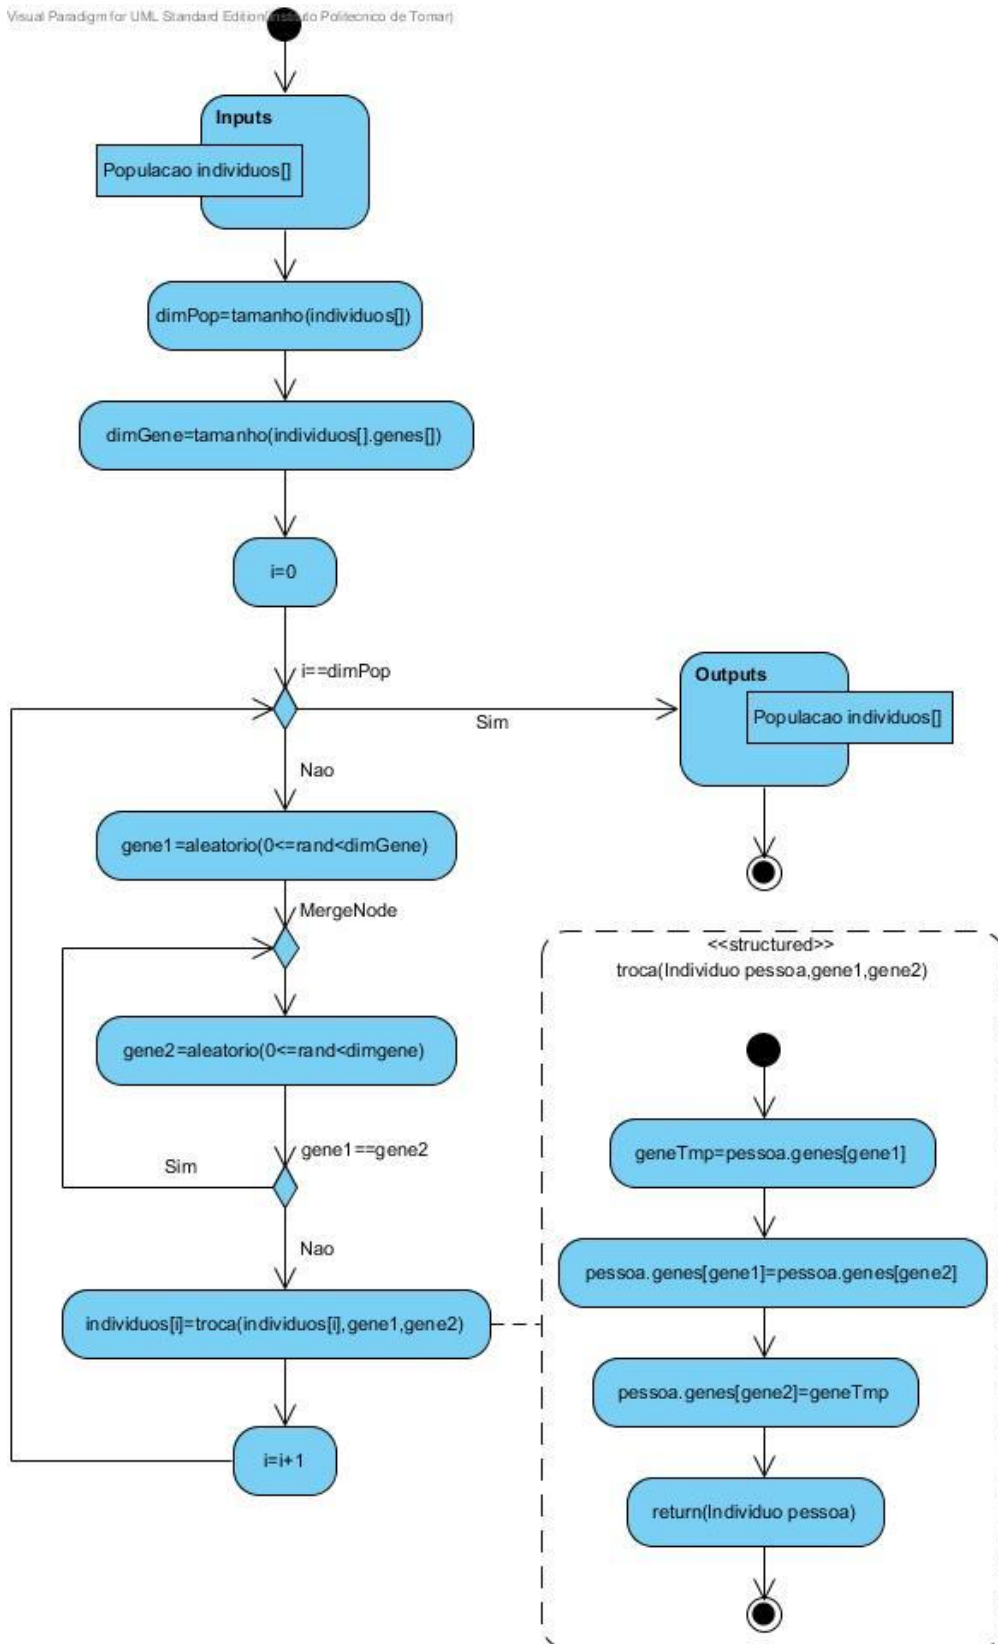
## Inversion Mutation

Visual Paradigm for UML Standard Edition (Instituto Politécnico de Tomar)



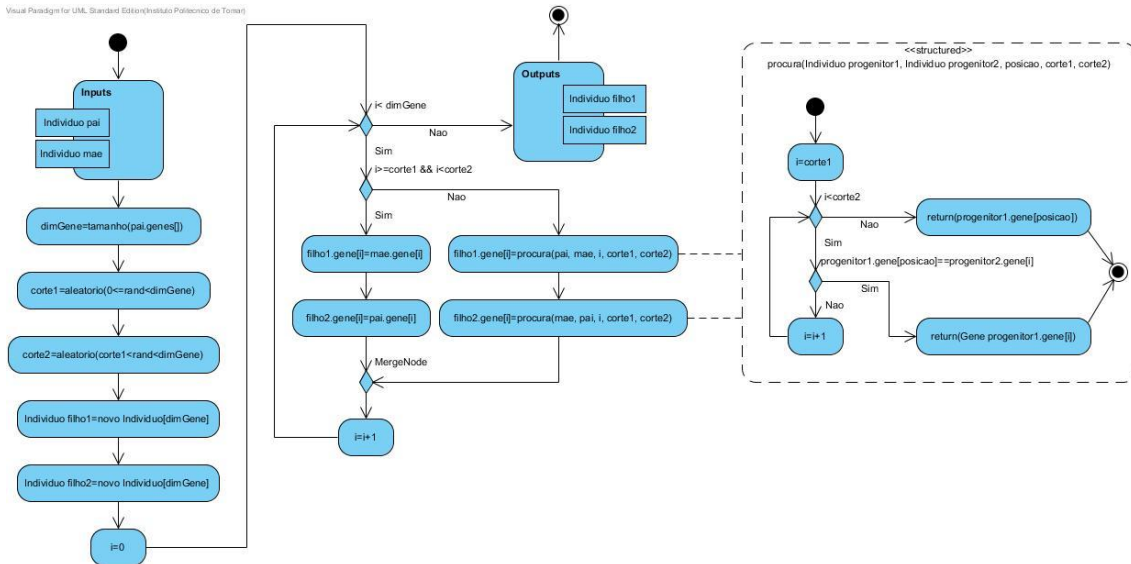
## Mutation

Visual Paradigm for UML, Standard Edition (Instituto Politécnico de Tomar)



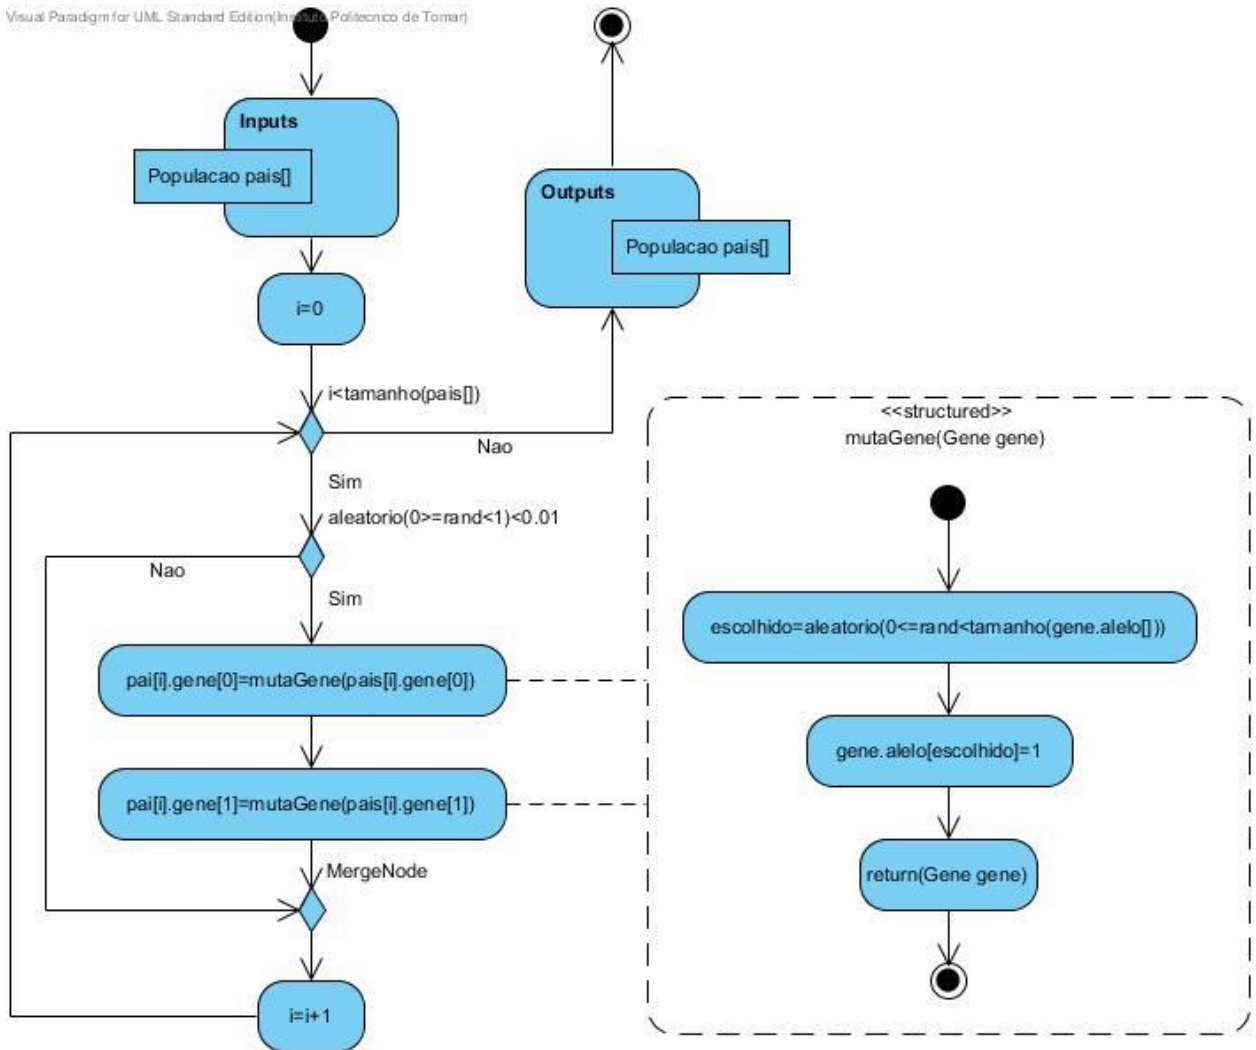
# PMX

Visual Paradigm for UML, Standard Edition (Instituto Politécnico de Tomar)



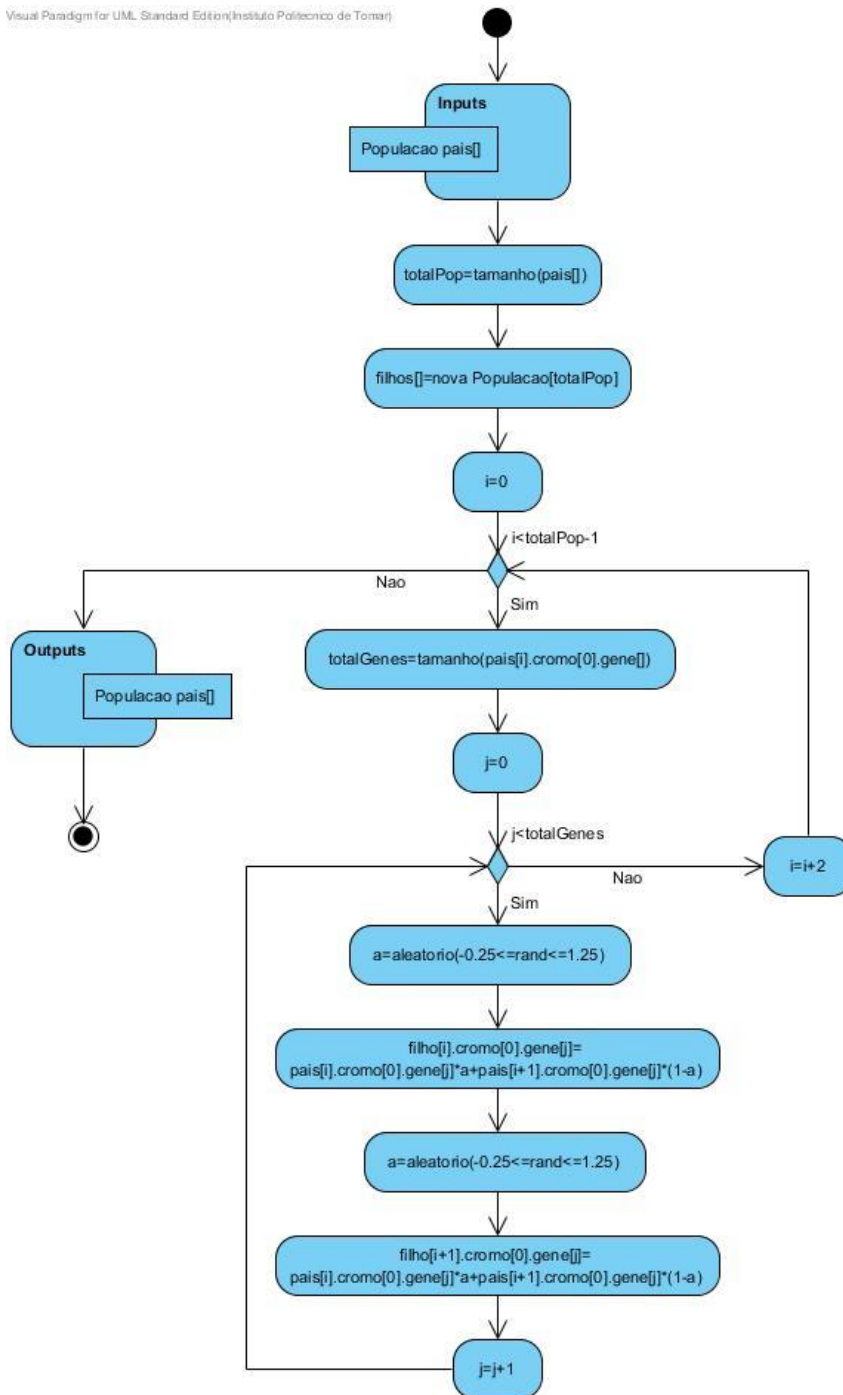
## Crossover

Visual Paradigm for UML Standard Edition (Instituto Politécnico de Tomar)



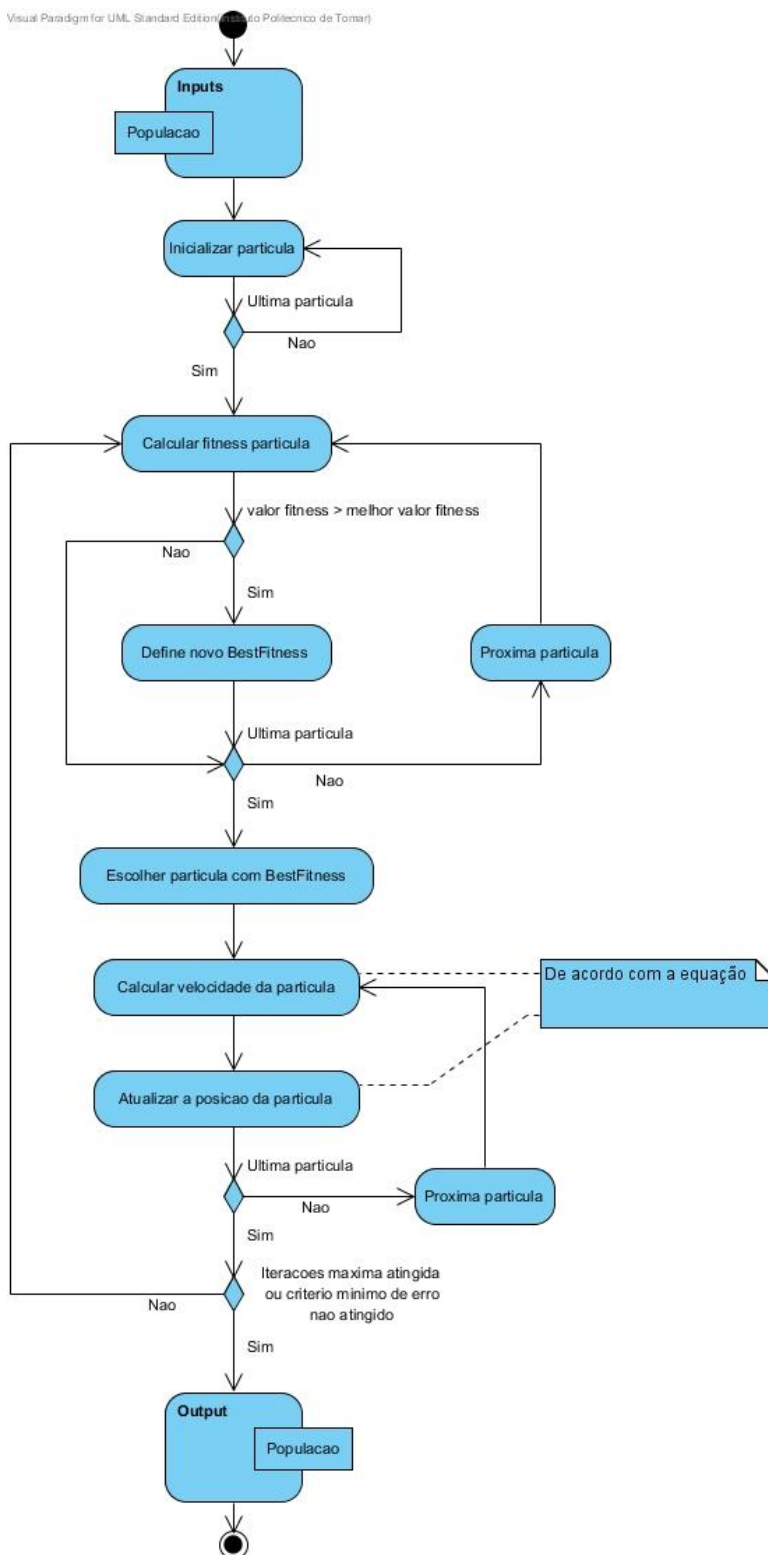
## Mutação Binária

Visual Paradigm for UML Standard Edition (Instituto Politécnico de Tomar)

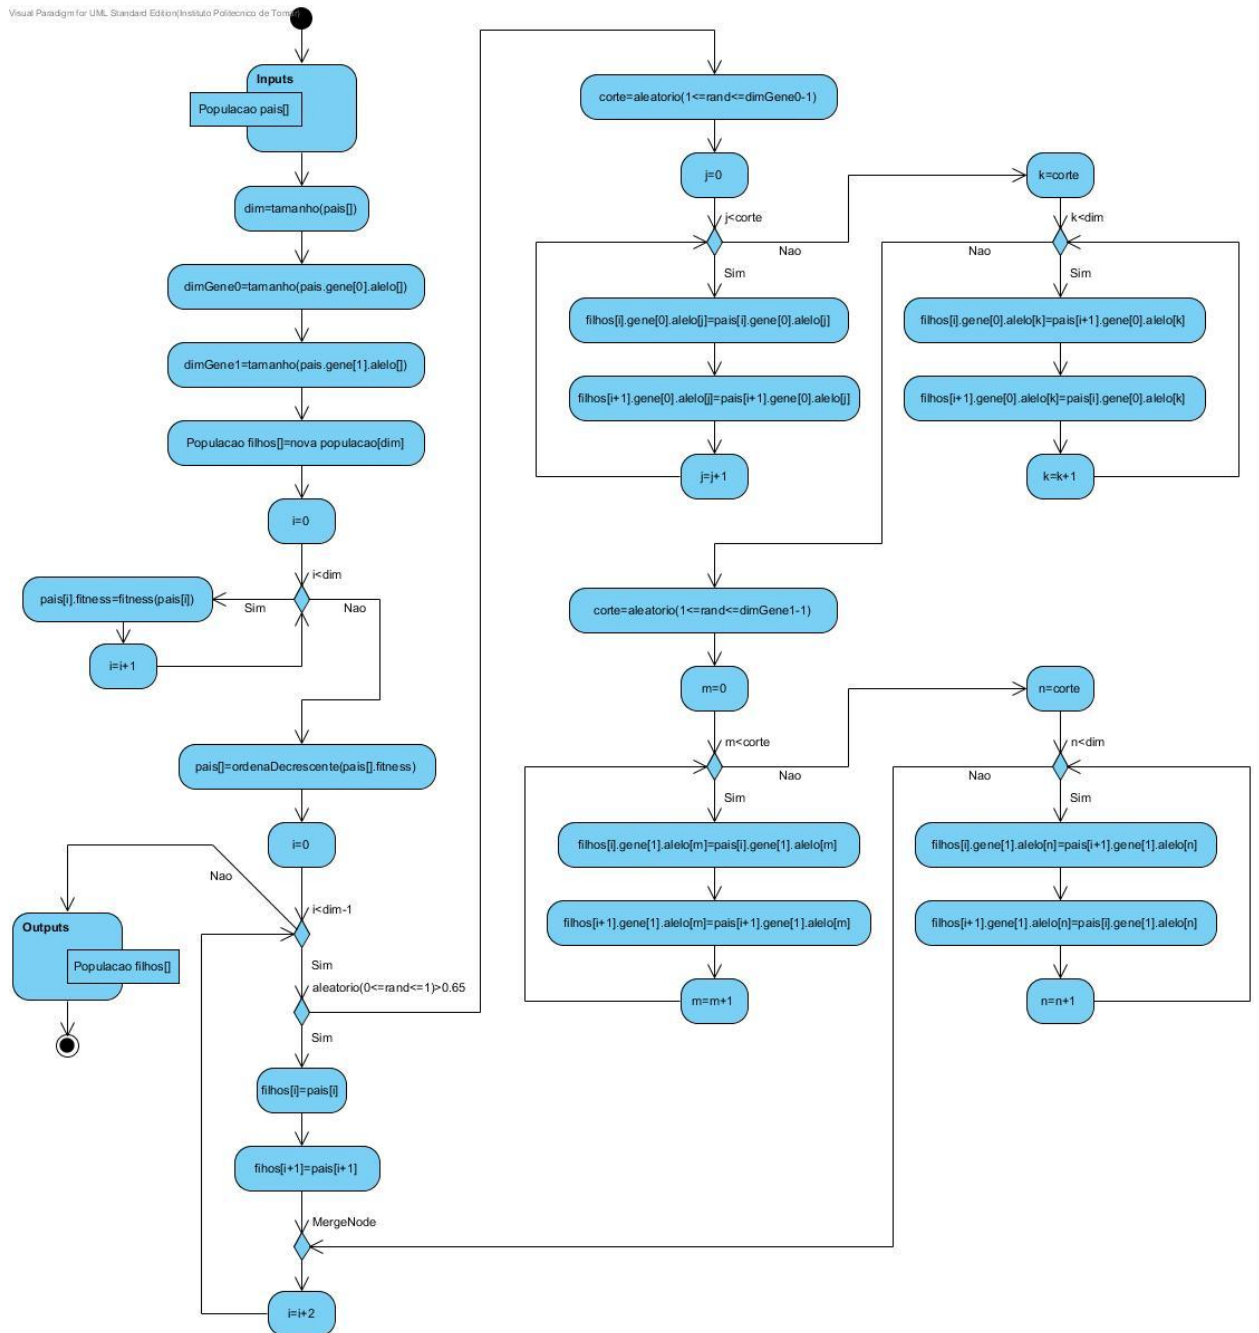


## P.S.O

Visual Paradigm for UML, Standard Edition (Copyright Politécnico de Tomar)



# Recombinação Binaria



## Pseudo-codigo

### Fitness Penalização

```
entra(População p[], pesoMax, peso[], valor[])

    para i := 0 ate i < tamanho(p[])
        p[i].fitness := fitnessPenal(p[i].genes[], pesoMax, peso[], valor[])
        i := i+1
sai(População p[])
fitnessPenal(Individuo genes[], pesoMax, peso[], valor[])
    para i := 0 ate i < tamanho(peso[])
        se genes[i] = 1 entao
            val := val+valor[i]
            pes := pes+peso[i]
        i := i+1
    se pes <= pesoMax entao
        fitness := val
    senao
        fitness := val-(pes-pesoMax)

    se fitness < 0 entao
        fitness := 0
    retorna fitness
```

### Reparação aleatória

```
entra(População p[], pesoMax, peso[], valor[])

    para i := 0 até i < tamanho(p[])
        p[i] := reparaAleatorio(p[i].genes[], pesoMax, peso[], valor[])
        i := i+1
sai(População p[])

reparaAleatorio(Individuo genes[], pesoMax, peso[], valor[])
    dim := tamanho(genes[])
    para i := 0 ate i < dim
        se genes[i] = 1 entao
            val := val+valor[i]
            pes := pes+peso[i]
        i := i+1

    se pes <= pesoMax entao
        Individuo genes[].fitness := val
        retorna genes[]
    senão
        fazer
            n := aleatorio([0;dim])
```



```

    enquanto (genes[n] = 0)
        genes[n] := 0
    retorna reparaAleatorio(genes[])

```

## Reparação aleatória

entra(População p[], pesoMax, peso[], valor[])

```

    para i := 0 até i < tamanho(p[])
        p[i] := reparaPseudoAleatorio(p[i].genes[], pesoMax, peso[], valor[])
        i := i+1

```

sai(População p[])

reparaPseudoAleatorio(Cromossoma genes[], pesoMax, peso[], valor[])

```

    dim := tamanho(genes[])
    para i := 0 até i < dim
        se genes[i] = 1 então
            val := val+valor[i]
            pes := pes+peso[i]
            i := i+1
    se pes <= pesoMax então
        Cromossoma genes[].fitness := val
        retorna genes[]
    senão
        para i := 0 até i < dim
            novo relacao[i] := valor[i]/peso[i]
        fazer
            k := k+1
            n := menor(ordem:=k : relacao[])
        enquanto (genes[n] = 0)
            genes[n] := 0
        retorna reparaPseudoAleatorio(genes[])

```

## Operador crossover

entra(População p[], individuosPretendidos)

```

    para i := 0 até i < individuosPretendidos
        Individuo pai := aleatório(p[])
        fazer
            Individuo mae := aleatório(p[])
        enquanto (pai = mae)
            para j := 0 até j < pai.totalGenes
                n := aleatório({falso, verdadeiro})
                se n = falso então
                    f[i].gene[j] := pai.gene[j]
                    f[i+1].gene[j] := mae.gene[j]

```

```

                senao
                    f[i].gene[j] := mae.gene[j]
                    f[i+1].gene[j] := pai.gene[j]
                j := j+1
            i := i+2

sai(População f[])

```

## Operador Roleta

```

entra(População pop[], individuosPretendidos)

    dim := tamanho(pop[])

    para i := 0 ate i < dim
        pop[i].fitness := fitness(pop[i])
        fitnessTotal := fitnessTotal+pop[i].fitness
        i := i+1

    pop[] := ordenaDecrescente(pop[].fitness)

    pop[0].probabilidadeAcumulada := pop[0].fitness/fitnessTotal
    para i := 1 ate i < dim
        pop[i].probabilidadeAcumulada := (pop[i].fitness/fitnessTotal)+pop[i-1].probabilidadeAcumulada
        i := i+1

    para i := 0 ate i < individuosPretendidos
        n := aleatório([0;1])
        Indivíduo ind[i] := procura(n : pop[].probabilidadeAcumulada)
        i := i+1

sai(População ind[])

```

## Operador SUS

```

entra(Populacao pop[], individuosPretendidos)

    dim := tamanho(pop[])

    para i := 0 ate i < dim
        pop[i].fitness := fitness(pop[i])
        i := i+1

    pop[0].fitnessAcumulada := pop[0].fitness
    para i := 1 ate i < dim
        pop[i].fitnessAcumulada := pop[i].fitness + pop[i-1].fitnessAcumulada
        i := i+1

    totalFitness := pop[dim-1].fitnessAcumulada

    offset := totalFitness/dim

    n := aleatorio([0;totalFitness])

```

```

indivíduo ind[0] := procurar(n : pop[],fitnessAcumulada)

para i := 1 ate i < individuosPretendidos
    n := n+offset
    n := n%dim
    Indivíduo ind[i] := procurar(n : pop[],fitnessAcumulada)
    i := i+1

```

```
sai(Populacao ind[])
```

## Operador Truncation

```
entra(Populacao popA[], População popB[])
```

```

dim1 := tamanho(popA[])
dim2 := tamanho(popB[])

nova Populacao popT[dim1+dim2]

para i := 0 ate i < dim1+dim2
    se i < dim1 então
        popT[i] := popA[i]
    senao
        popT[i] := popB[i-dim1]
    i := i+1

para i := 0 ate i < tamanho(popT[])
    fitness(popT[i])
    i := i+1

popT[] := ordenaDecrescente(popT[])

para i := 0 ate i < dim1
    popA[i] := popT[i]
    i := i+1

```

```
sai(Populacao popA[])
```

## Crossover

entra(Individuo pai, Individuo mae)

dim := tamanho(pai.genes[])

corte := aleatorio([1;dim-1])

para i := 0 até i < corte

    filho.gene[i] := pai.gene[i]

    filha.gene[i] := mae.gene[i]

    i := i+1

para j := corte até j < dim

    filho.gene[j] := procura(j, mae.gene[], filho.gene[])

    filha.gene[j] := procura(j, pai.gene[], filha.gene[])

    j := j+1

sai(Individuo filho, Individuo filha)

procura(pos, progenitor.gene[], descendente.gene[])

    p := pos-1

    q := pos

    enquanto (p >= 0)

        se (descendente.gene[p] = progenitor.gene[q]) entao

            q := q+1

            q := q%tamanho(progenitor.gene[])

            p := pos

        p := p-1

    retorna progenitor.gene[q]

## Inversion Mutation

```
entra(População individuos[])

    dimPop := tamanho(individuos[])
    dimGene := tamanho(individuos[].genes[])

    para i := 0 ate i < dimPop
        gene1 := aleatorio(0<=rand<dimGene)
        gene2 := aleatorio(gene1<=rand<dimGene)

        enquanto(gene1 < gene2) fazer
            troca(individuos[i], gene1, gene2)
            gene1 := gene1+1
            gene2 := gene2-1

        i := i+1

sai(População individuos[])
```

```
troca(Individuo pessoa, gene1, gene2)

    geneTmp := pessoa.genes[gene1]
    pessoa.genes[gene1] := pessoa.genes[gene2]
    pessoa.genes[gene2] := geneTmp

retorna(Individuo pessoa)
```

## Mutation

```
entra(População individuos[])

    dimPop := tamanho(individuos[])
    dimGene := tamanho(individuos[].genes[])

    para i := 0 ate i = dimPop
        gene1 := aleatorio(0<=rand<dimGene)
        fazer
            gene2 := aleatorio(0<=rand<dimGene)
        enquanto(gene1 = gene2)

        individuos[i] := troca(individuos[i], gene1, gene2)
        i := i+1
```

```
sai(População individuos[])
```

```
troca(Individuo pessoa, gene1, gene2)
```

```
geneTmp := pessoa.genes[gene1]
pessoa.genes[gene1] := pessoa.genes[gene2]
pessoa.genes[gene2] := geneTmp
```

```
retorna(Individuo pessoa)
```

## PMX

```
entra(Individuo pai, Individuo mae)
```

```
dimGene := tamanho(pai.genes[])
corte1 := aleatorio(0<=rand<dimGene)
corte2 := aleatorio(corte1<rand<dimGene)
Individuo filho1 := novo Individuo[dimGene]
Individuo filho2 := novo Individuo[dimGene]
para i := 0 ate i < dimGene
    se(i >= corte1 e i < corte2) entao
        filho1.gene[i] := mae.gene[i]
        filho2.gene[i] := pai.gene[i]
    senao
        filho1.gene[i] := procura(pai, mae, i, corte1, corte2)
        filho2.gene[i] := procura(mae, pai, i, corte1, corte2)
    i := i+1
```

```
sai(Individuo filho1, Individuo filho2)
```

```
procura(Individuo progenitor1, Individuo progenitor2, posicao, corte1, corte2)
```

```
para i := corte1 ate i < corte2
    se(progenitor1.gene[posicao] = progenitor2.gene[i])
        retorna(Gene progenitor1.gene[i])
    i := i+1
```

```
retorna(Gene progenitor1.gene[posicao])
```

## SUS Minimização

```
entra(População individuos[])
```

```
maxFitness := maiorFitness(individuos[])+1
```

```
para i := 0 ate i < tamanho(individuos[])
    individuos[i].fitness := maxFitness-individuos[i].fitness
    i := i+1
```

```
sai(População individuos[])
```

```

maiorFitness(individuos[])
    max := 0
    para i := 0 ate i < tamanho(individuos[])
        se (max < individuos[i].fitness) entao
            max := individuos[i].fitness
        i := i+1

    retorna max

```

## Crossover

```

entra(Populacao pais[])
    totalPop := tamanho(pais[])
    filhos[] := nova Populacao[totalPop]
    para i := 0 ate i < totalPop-1 fazer
        totalGenes := tamanho(pais[i].cromo[0].gene[])
        para j := 0 ate j < totalGenes fazer
            a = aleatorio(-0.25<=rand<=1.25)
            filho[i].cromo[0].gene[j] := pais[i].cromo[0].gene[j] * a + pais[i+1].cromo[0].gene[j] * (1-a)
            a = aleatorio(-0.25<=rand<=1.25)
            filho[i+1].cromo[0].gene[j] := pais[i].cromo[0].gene[j] * a + pais[i+1].cromo[0].gene[j] * (1-a)
            j := j+1
        i := i+2
    sai(Populacao pais[])

```

## Mutação binaria

```

entra(Populacao pais[])
    para i := 0 até i < tamanho(pais[])
        se (aleatorio(0<=rand<1) < 0.01) entao
            //percorre a população progenitora
            //se factor de ponderação for
            menor,
                pais[i].gene[0] := mutaGene(pais[i].gene[0])
                pais[i].gene[1] := mutaGene(pais[i].gene[1])
                //que 1% entao
                //muta o alelo em causa
            i := i+1
    //nova iteração
    sai(Populacao pais[])

```

```

mutaGene(Gene gene)
    escolhido := aleatorio(0<=rand<tamanho(gene.alelo[]))
    gene.alelo[escolhido] := 1
    //alelo escolhido aleatoriamente
    //toma o
    valor de verdadeiro
    retorna(Gene gene)

```

## PSO

entra(Populacao pop[])

```
Para cada pop[].particula
    Inicializar pop[i].particula
Fazer
    Para cada pop[].particula
        calcularValor(pop[i].particula.fitness)
        Se (valor de fitness > melhor valor de fitness (pBest))
            definaValor(pBest)
    gBest := particula com o melhor valor de fitness
    Para cada pop[].particula
         $v[] := v[] + c1 * \text{rand}() * (\text{pbest}[] - \text{present}[]) + c2 * \text{rand}() * (\text{gbest}[] - \text{present}[])$ 
         $\text{present}[] := \text{persent}[] + v[]$ 
    Enquanto (iterações máximas não forem atingidas ou critérios mínimos erro não forem atingidos)
```

sai(Populacao pop[])

## Recombinacao\_binaria

entra(Populacao pais[])

```
dim := tamanho(pais[])
//numero de individuos da população progenitora
dimGene0 := tamanho(pais[].gene[0].alelo[])
//dimensao do primeiro gene
dimGene1 := tamanho(pais[].gene[1].alelo[])
//dimensao do segundo gene
Populacao filhos[] := nova Populacao[dim]
//criação de uma geração vazia do tamanho da população progenitora
para i := 0 até i < dim
    //percorrer a população progenitora
    pais[i].fitness := fitness(pais[i])
//calculo do fitness dos individuos da população progenitora
    i := i+1
//nova iteração
pais[] := ordenaDecrescente(pais[].fitness)
//ordena a população progenitora pelo valor do fitness decrescente
para i := 0 até i < dim-1
    //ciclo para recombinação dos individuos
    se (aleatorio(0<=rand<=1) > 0.65) entao
        //se factor de ponderação for maior,
        filhos[i] := pais[i]
        // entao os individuos transitam como estao
```



```

        filhos[i+1] := pais[i+1]
    //
    senao
        //se factor de ponderação não for maior,
        corte := aleatorio(1<=rand<=dimGene0-1)
    //calculo do ponto de corte do primeiro gene
    para j := 0 até j < corte
        //até ao corte do primeiro gene
        filhos[i].gene[0].alelo[j] := pais[i].gene[0].alelo[j]           //copia dos pais para
os filhos
        filhos[i+1].gene[0].alelo[j] := pais[i+1].gene[0].alelo[j] //
        j := j+1
        //nova iteração
    para k := corte até k < dim
        //depois do corte do primeiro gene
        filhos[i].gene[0].alelo[k] := pais[i+1].gene[0].alelo[k] //copia dos pais para os filhos,
        filhos[i+1].gene[0].alelo[k] := pais[i].gene[0].alelo[k] //com os progenitores trocados
        k := k+1
        //nova iteração
        corte := aleatorio(1<=rand<=dimGene1-1)
    //calculo do ponto de corte do segundo gene
    para m := 0 até m < corte
        //até ao corte do segundo gene
        filhos[i].gene[1].alelo[m] := pais[i].gene[1].alelo[m]           //copia dos pais para
os filhos
        filhos[i+1].gene[1].alelo[m] := pais[i+1].gene[1].alelo[m] //
        m := m+1
        //nova iteração
    para n := corte até n < dim
        //depois do corte do segundo gene
        filhos[i].gene[1].alelo[n] := pais[i+1].gene[1].alelo[n] //copia dos pais para os filhos
        filhos[i+1].gene[1].alelo[n] := pais[i].gene[1].alelo[n] //com os progenitores trocados
        n := n+1
        //nova iteração
    i := i+2
        //nova iteração com um incremento de 2
    sai(Populacao filhos[])

```